



Санкт-Петербургский
государственный университет

Тема: Распределенный инференс глубоких нейросетевых моделей

Выполнил: Колосков Виктор Юрьевич

Научный руководитель: Першин Антон Юрьевич

Постановка задачи


Инференс нейросетевых моделей — это процесс использования уже обученной нейронной сети для предсказания результатов на новых, ранее невидимых данных.

Активное развитие технологий глубоких нейронных сетей привело к необходимости эффективного использования нескольких вычислительных устройств для выполнения инференса. Это обусловлено ограничениями памяти видеокарт и центральных процессоров при работе с крупными моделями.

Для решения этой проблемы возникает необходимость разделить матрицы весов модели между различными устройствами. Такой подход требует создания определенных "разрезов" нейронной сети, которые будут распределены по доступным ресурсам.


Цель: исследовать различные способы распределенного инференса и инструменты их реализации.

Разрезы нейронной сети




Примеры разрезов нейронной сети



Тензорный параллелизм




Конвейерный параллелизм




Архитектура MoE



Экспертный параллелизм



Оптимизации распределенного инференса




Фреймворки для распределенного инференса

	MindSpore	DeepSpeed	Megatron-LM
+	- Способен запускаться не только на GPU - MindIR	- Использует torch - Тесная интеграция с другими библиотеками - ZeRO	- Использует torch - Тесная интеграция с оборудованием NVIDIA
-	- Ограничения в библиотеках - Ограничения с GPU	Находится на ранней стадии	- Требует достаточно высокой компетенции - Не оптимизирован под инференс


Практические эксперименты

- Параллелизм по данным
- Тензорный параллелизм
- ZeRO с выгрузкой параметров на NVMe
- ZeRO с выгрузкой параметров на CPU
- Параллелизм по данным с ZeRO
- Тензорный параллелизм с ZeRO
- Экспертный параллелизм
- Смешанный параллелизм: тензорный + экспертный


Параллелизм по данным и тензорный параллелизм



Параллелизм по данным и тензорный параллелизм




ZeRO с CPU и NVMe




Тензорный параллелизм с ZeRO и без


latency (s) vs Model Size




Использование ZeRO с DP и TP



Экспертный параллелизм с тензорным и без



Экспертный параллелизм с тензорным и без



Выводы

1. Исследованы различные способы параллелизма моделей и изучены их основные преимущества и недостатки
2. Рассмотрены подходы к оптимизации распределённого инференса
3. Проведён анализ существующих фреймворков, предоставляющих инструменты для реализации распределённого инференса
4. Проведены практические эксперименты с некоторыми видами параллелизма и показаны их определенные преимущества и недостатки

Thank you for your attention



Сгенерировано нейросетью Qwen3